



[딥러닝 실습 보고서] 현대적 CNN: ConvNeXt V2 성능 및 메커니즘 분석

실험 일자: 2026년 4월 12일

사용 장비: NVIDIA GeForce RTX 3070 Ti (8GB VRAM)

1. 실험 목적 (Introduction)

- CNN의 효율성과 Transformer의 학습 기법을 결합한 최신 아키텍처인 **ConvNeXt V2**의 성능을 검증함.
- FCMAE(Fully Convolutional Masked Autoencoder)** 방식의 사전 학습 모델이 소규모 데이터셋(Flowers30)에서 보여주는 전이 학습 효율성을 분석함.
- GRN(Global Response Normalization)** 레이어를 통한 특징 붕괴(Feature Collapse) 방지 효과를 정량적으로 확인함.

2. 실험 환경 및 데이터 (Environment & Dataset)

- Framework:** PyTorch 2.5.1 / CUDA 12.1
- Dataset:** Flowers30 (총 10,784장)
- Data Split (Seed 42):** * **Train:** 7,548장 (70%)
 - Validation:** 1,617장 (15%)
 - Test:** 1,619장 (15%)
- Hyperparameters:** Epochs=10, Batch Size=32, Optimizer=AdamW (lr=1e-4, weight_decay=0.05)

Training Log 요약:

- 초기 (**Epoch 0**): Train Loss: 1.4168 / Val F1: 0.8048
- 최종 (**Epoch 9**): Train Loss: 0.0278 / Val F1: 0.9036
- 분석: 학습 3에폭 만에 F1-Score 0.95를 돌파하며 매우 빠른 수렴 속도를 보임. 이는 FCMAE 사전 학습 가중치가 이미지의 핵심 특징을 이미 잘 파악하고 있음을 시사함.

3. 최종 테스트 결과 (Final Test Evaluation)

전체 정확도(Accuracy): 90% Weighted F1-Score: 0.90

학습속도: 6m 36.9s

주요 클래스	Precision	Recall	F1-Score	Support
Acacia	0.73	0.98	0.84	47
Freesia	0.83	0.78	0.80	55
Calceolaria	1.00	0.97	0.98	59
Guzmania	0.98	0.98	0.98	63

평가: 대부분의 클래스에서 0.90 내외의 높은 F1-Score를 기록함. 특히 **Acacia**의 경우 Recall이 0.98에 달해 실제 아카시아 이미지를 거의 놓치지 않고 찾아내는 성능을 보임.

4. 실전 추론 및 심화 분석 (Inference & Analysis)

4.1. 단일 이미지 예측 테스트






- **Case 1 (Acacia):** Confidence ****99.71%****로 정확히 예측.
- **Case 2 (Freesia):** Confidence ****98.11%****로 정확히 예측.

- 시사점: 모델이 배경과 피사체를 명확히 구분하여 높은 확신도로 분류하고 있음을



4.2. 특징 붕괴(Feature Collapse) 및 FCMAE 검증

- 마스킹 실험: 이미지의 60%를 가린 상태에서도 핵심 특징을 추출함.
- 특징 다양성 점수: **0.9982 ~ 1.0001** 달성.
- 결론: GRN 레이어가 각 채널의 활성화를 독립적으로 유지하여, 정보가 하나로 뭉치는 '특징 붕괴' 현상 없이 풍부한 표현력을 유지하고 있음을 통계적으로 입증함.



5. 최종 결론 (Conclusion)

1. 성능 우수성: ConvNeXt V2는 Atto라는 매우 가벼운 사이즈임에도 불구하고, 현대화된 구조를 통해 90%의 높은 정확도를 기록함.
2. 이론 구현 성공: 논문에서 강조한 GRN의 효과를 특징 다양성 점수를 통해 직접 검증하였으며, 이는 단순 분류를 넘어 모델의 내부 메커니즘을 통제했음을 의미함.
3. 향후 과제: 현재 수렴 속도가 매우 빠르므로, 더 강력한 Data Augmentation을 적용한다면 95% 이상의 성능 향상이 가능할 것으로 기대됨.

6. ConvNeXt V2 코드 뜯어보기 (Architecture Analysis)

🌱 [1] Depthwise Convolution (공간 정보 추출)

```
self.dwconv = nn.Conv2d(dim, dim, kernel_size=7, padding=3, groups=dim)
```

- **dim**: 입력 데이터의 특징 차원(Channel) 수이다. Atto 모델 기준 초기 단계에서 약 40~80개의 차원을 할당하여 기초 특징을 수집한다.
- **kernel_size=7**: 전통적인 CNN의 3x3 커널을 탈피하고 **7x7** 대형 커널을 채택하였다. 이는 이미지의 국소적인 패턴을 넘어, 모델이 더 넓은 문맥(Global Context)과 전역적인 구도를 한 번에 파악할 수 있게 한다.
- **groups=dim**: **Depthwise** 방식을 적용하여 각 채널을 독립적으로 연산한다. 이는 파라미터 수와 연산량을 획기적으로 줄임으로써 모델의 효율성을 극대화하는 핵심 기법이다.

🧩 [2] Layer Normalization (데이터 정규화)

```
self.norm = LayerNorm(dim, eps=1e-6, data_format="channels_last")
```

- **eps=1e-6**: 분모가 0이 되는 수치적 불안정성을 방지하기 위한 미세값이다. 통계적 계산의 안정성을 확보하여 안정적인 학습을 지원한다.
- **channels_last**: 데이터를 (Batch, Height, Width, Channel) 순으로 재배치한다. 이는 Transformer 계열 모델의 데이터 처리 컨벤션을 따른 것으로, 메모리 접근 효율을 최적화하고 최신 가속기 환경에 적합한 구조를 갖춘다.

🧩 [3] Pointwise MLP (차원 확장 및 특징 생성)

```
self.pwconv1 = nn.Linear(dim, 4 * dim)
self.act = nn.GELU()
self.pwconv2 = nn.Linear(4 * dim, dim)
```

- **4 * dim**: 입력 차원을 4배로 팽창시켜 고차원 특징 공간(Feature Space)을 생성한다. 데이터를 넓은 공간으로 투영함으로써 더 복잡하고 미세한 비선형 특징들을 학습할 수 있는 환경을 조성한다.
- **GELU()**: 정규 분포의 누적 분포 함수를 이용한 활성화 함수이다. ReLU 대비 부드러운 곡선을 형성하여 정보 손실을 최소화하고 비선형성을 부여한다.
- **pwconv2**: 확장된 공간에서 추출된 방대한 정보 중 유의미한 데이터만을 다시 원래의 차원으로 압축하여 다음 계층으로 전달한다.

🧩 [4] GRN (Global Response Normalization - 핵심 변수)

```
# GRN 내부 연산 로직
gx = torch.norm(x, p=2, dim=(1, 2), keepdim=True) # 채널별 에너지(L2-Norm)
nx = gx / (gx.mean(dim=-1, keepdim=True) + 1e-6) # 상대적 중요도 정규화
x = self.gamma * (x * nx) + self.beta + x # 특징 강화 및 잔차 연결
```

- **gx (Global Feature):** 각 채널의 L2-Norm을 계산하여 채널별 '반응 강도(에너지)'를 정량화한다.
 - **nx (Normalized Feature):** 특정 채널의 정보 독점을 방지하기 위해 전체 채널의 평균 에너지로 정규화한다.
 - **gamma & beta:** 학습 가능한 파라미터로서, 모델이 스스로 어떤 특징 채널이 중요한지 가중치를 동적으로 조절하게 한다.
 - **역할:** 본 실습의 시각화 결과에서 확인된 *****특징 다양성*****을 유지하는 중추적인 장치이다. 채널 간 경쟁을 유도하여 정보의 중복을 억제하고 표현력을 극대화한다.
-

최종 동작 방식 정리 (Summary of Process)

ConvNeXt V2는 입력 이미지를 다음과 같은 통계적·공학적 프로세스를 통해 처리한다.

1. **전역 수용 (Large Kernel):** 대형 커널 필터를 통해 사물의 전체적인 형태와 구도를 선제적으로 파악한다.
2. **정규화 (LayerNorm):** 학습 데이터의 분포를 균일하게 조정하여 최적화 효율을 높인다.
3. **비선형 확장 (Inverted Bottleneck):** 특징 공간을 일시적으로 확장하여 미세한 질감 및 고차원 정보를 정밀하게 추출한다.
4. **채널 최적화 (GRN):** 추출된 특징 중 중복된 정보를 억제하고, 상호 보완적인 고유 정보들이 남도록 채널 간 가중치를 재조정한다.
5. **정보 보존 (Residual Connection):** 잔차 연결(Skip Connection)을 통해 원본 데이터를 보존함으로써, 깊은 계층 구조에서도 정보 소실 없이 학습의 안정성을 유지한다.